

Desafios na identificação automática de grupos econômicos para aprimorar a gestão de riscos e controle de crédito.

Gustavo de Paula Aguiar Araújo ^{1*}; Diego de Oliveira Da Cunha

¹ Universidade de São Paulo - Bacharelado em Sistemas da informação. Rua Arlindo Béttio, 1000 - Ermelino Matarazzo, São Paulo - SP, 03828-000

¹ Faculdade de Informática e Administração Paulista – MBA Engenharia de Software aplicado em SOA. Faculdade de Informática e Administração Paulista.

Desafios na identificação automática de grupos econômicos para aprimorar a gestão de riscos e controle de crédito.

Resumo

A gestão de risco de crédito sempre foi essencial para a estabilidade das instituições financeiras e para a economia como um todo. O trabalho propôs a criação de um algoritmo que permitiu identificar estruturas de Grupos Econômicos (GEs) a partir de vínculo societário, com o objetivo de melhorar e ampliar a análise de risco de crédito nas instituições financeiras [IFs], partindo de uma análise mais profunda dos envolvidos na gestão do crédito. Utilizando conceitos da teoria dos grafos, o algoritmo mapeou as relações entre empresas e sócios, e disponibilizou a visão das conexões que existiam entre as empresas e seus sócios. Os resultados mostraram que a abordagem permitiu uma avaliação mais precisa do risco de crédito, facilitou a gestão proativa das carteiras e aprimorou a capacidade das IFs para tomar melhores decisões ao conceder crédito.

Palavras-chave: carteira de crédito; vínculo entre empresas; grafos por relação de empresas;

Introdução

Há muito tempo, instituições financeiras [IFs] e não financeiras têm se preocupado com a gestão eficaz do risco de crédito (IPEA, 2006). Os eventos complexos que resultaram em impactos significativos nas economias e sociedades, tais como, recessões e crises financeiras, imprimiram desafios e impulsionaram o desenvolvimento de estratégias para reduzir a exposição ao risco de crédito, maximizar os lucros e manter a sustentabilidade no mercado (Jassé, 2020). Esses desafios impulsionaram o desenvolvimento de estratégias para reduzir a exposição ao risco de crédito, maximizar os lucros e manter a sustentabilidade no mercado.

Uma das principais atividades bancárias é a concessão de crédito, a qual possibilita a expansão natural do mercado através da troca de recursos financeiros entre provedor e tomador. O fato da exposição a inadimplência, ou seja, do descumprimento do acordo de retorno dos recursos financeiros emprestados ao tomador pelo provedor, exige ao provedor conhecer melhor o tomador, antes de assumir o risco da transferência do recurso financeiro. Dessa forma, a necessidade de controlar e garantir o menor risco de concessão de crédito é fundamental e essencial para garantir a saúde do ambiente financeiro atual e futuro. (Gestel e Baesens, 2008)

A gestão de risco de crédito, ao longo do tempo, teve diferentes marcos que contribuíram para seu amadurecimento. Até o início do século XX, a análise e aprovação de crédito ainda era feita subjetivamente, dependendo somente do julgamento de analistas. Esse método, além de não utilizar critérios objetivos, era moroso e não considerava uma análise ampla, com todas as variáveis da exposição ao risco de crédito para as IFs, tornando-se de certa forma subjetivo (Camargos, 2012). Com o advento de novas tecnologias e modelos estatísticos, foi possível desenvolver maneiras mais eficientes para controlar carteiras de créditos, criando mecanismos para conhecer melhor seus clientes.

É nesse contexto em que é introduzido o conceito de grupo econômico [GE]. Essa terminologia é dada ao conjunto de empresas que, estão interligadas por relações contratuais, cuja propriedade pertence a indivíduos ou instituições, que exercem o controle efetivo sobre essas empresas (Gonçalves, 1991). A identificação e correlação dos indivíduos de um GE é de grande importância para aprimorar os modelos de precificação de risco de crédito, garantindo uma maior pluralidade nas informações dos envolvidos na concessão de crédito.

Desta forma, em 2017 o Banco Central Brasileiro [BACEN] propõe a regulamentação do controle de contrapartes para fins de gerenciamento de risco. A resolução propõe e exige que as IFs realizem o controle de contrapartes conectadas que compartilhem risco de crédito, documentando os critérios utilizados para identificação de cada indivíduo pertencente ao GE (BACEN, 2017, Art. 22). A norma é prerrogativa para definições das diretrizes e requisitos para a estrutura de gerenciamento de riscos e apetite por riscos nas instituições financeiras, visando a promover uma gestão prudente e eficaz das suas carteiras.

É neste contexto que o presente trabalho tenta demonstrar que é possível criar maneiras de identificar melhor os vínculos entre empresas e sócios, desenvolvendo um algoritmo que auxilie a identificação de clientes envolvidos na concessão de crédito. Foca na identificação de possíveis estruturas de GEs para facilitar a identificação de relações entre empresas e seus sócios, o que possibilita uma melhor condução na análise de risco de crédito nas IFs. Ao identificar essas relações de maneira automatizada, é possível tomar decisões mais informadas e reduzir a exposição ao risco de crédito. Em outras palavras, o artigo descreve como é possível criar esse modelo e com isso facilita identificar as ligações entre as contrapartes envolvidas na concessão de crédito.

Material e Métodos

Nesta sessão do trabalho, é apresentado o processo de criação e organização da construção do algoritmo de agrupamento de GEs, assim como as ferramentas e desafios do processo. Em seguida, são apresentados alguns dos resultados do algoritmo.

Metadados

Os dados privados de cada indivíduo foram preservados e somente foram utilizados dados públicos de participação societária de empresas disponibilizados pelo Ministério da Economia [ME]. Os dados utilizados para a realização das análises do trabalho são de propriedade pública disponibilizados pela Secretaria Especial da Receita Federal do Brasil [RFB], os quais podem ser acessados através do canal Dados Abertos (Governo do Brasil, 2024).

Devido a quantidade de informação disponível, foi necessário à obtenção de uma ferramenta a qual pudesse disponibilizar as informações de forma massiva. Desta forma, foram utilizadas as informações centralizadas pelo site *base dos dados* (Base dos dados, 2024), o qual, de forma independente, centraliza a ingestão dos dados públicos da receita federal e disponibiliza os dados publicamente na ferramenta *BigQuery* do *Google*. Essa ferramenta, disponibilizada, possibilita a análise de dados gerenciados em larga escala (Google BigQuery, 2023). A utilização da ferramenta foi essencial para o processo de Data Wrangling, etapa fundamental para organizar os dados que foram utilizados para a modelagem do algoritmo, visto que foi necessária a análise de toda composição societária disponível.

Data Wrangling- tratamento de dados

Para obtenção dos dados, foi necessário criar uma estrutura de análise espelho das bases fornecidas pela RFB, a fim de estudar as estruturas e vínculos entre as bases e suas respectivas observações (Imagem 1 do Apêndice A).

A obtenção dos dados em larga escala trouxe maior complexidade para realizar a gestão dos dados, pois com a existência de milhares de observações disponíveis a execução ficou prejudicada devido ao tratamento dos dados em hardware não escalonável. Sendo assim, para o projeto, se optou à utilização da ingestão de dados diretamente do *BigQuery* com a persistência de dados em uma base de dados local, MySQL.

Como mostrado na Figura 1, com a utilização dos dados mascarados para os sócios, foi necessária a criação de uma chave de referência entre as empresas e sócios, para possibilitar a criação de um vínculo único entre as observações. Para a visão das empresas, foi concatenado o número básico do CNPJ com o nome da empresa. Já para os sócios, seguiu-se a mesma lógica, concatenando o nome do sócio com um algoritmo de

maskamento e a base do CPF ou CNPJ mascarado. Essas chaves possibilitam alimentar os grafos e criar as referências e vínculos entre os integrantes do GE.

empresas	socios
08169126-FR COMERCIO DE CALCADOS E ACESSORI...	ACMDO*****_***364671**
08169126-FR COMERCIO DE CALCADOS E ACESSORI...	AJM*****_***599401**
24705950-RESTAURANTE CANTINHO DO SABOR LTDA	AJM*****_***599401**
24705950-RESTAURANTE CANTINHO DO SABOR LTDA	DM*****_***643061**

Figura 1 - Chaves únicas de referência entre empresas e sócios

Fonte: Resultados originais da pesquisa

Grafos

A teoria dos grafos é uma das áreas da matemática que se dedica ao estudo de diagramas, estruturas matemáticas utilizadas para representar relações entre indivíduos. Um diagrama é composto por nós (também conhecidos como vértices) ligados por linhas (também chamadas de arestas ou conexões). Os diagramas podem ser não direcionados, nos quais as linhas conectam os nós simetricamente, ou direcionados, nos quais as linhas conectam os nós assimetricamente (WILSON, 1996).

Em grafos direcionados, as arestas possuem uma direção clara, indicando um ponto de partida e um ponto de chegada. Isso é útil para representar relações unidirecionais, ou seja, relações que partem sempre de um nó para outro, demonstrando um fluxo contínuo de ligação entre nós, demonstrado na Figura 2. Observa-se que o nó 'A' se liga ao nó 'B' e o 'B' ao nó 'C', porém não existe nenhuma ligação ou vínculo do 'B' para o 'A', do 'C' para o 'B' e nem do 'C' para o 'A', ou seja, são vínculos unidirecionais. Rotas de entregas em aplicativos de entrega, podem ser consideradas um exemplo da utilização desse tipo de abordagem.




Figura 2. Grafo direcionado

Fonte: Resultados originais da pesquisa

Já em grafos não direcionados, as arestas não têm direção, indicando uma relação bidirecional ou mútua entre os vértices. Esse tipo de grafo é usado, por exemplo, para representar redes sociais ou conexões físicas, onde a relação entre os nós é simétrica.




Figura 3. Estrutura de Grado não direcionado

Fonte: Resultados originais da pesquisa

Método

Após a modelagem dos dados, foram desenvolvidos métodos para criação de subgrafos gerados pela interação das relações entre empresas e sócios. Na figura 1, pode-se avaliar um exemplo de como são identificadas as relações entre a empresa 'FR Comércio' e o 'Restaurante Catinho' através do sócio 'AJM'. A execução parte de três Dataframes¹, descritos como empresas, sócios e relação empresa e sócio. Em seguida, é executada massivamente

¹ DataFrame. Estrutura de dados bidimensional utilizada principalmente em bibliotecas como o 'pandas' no Python, que permite a manipulação de dados tabulares de forma eficiente. Um DataFrame é comparável a uma tabela em uma base de dados ou a uma planilha, onde os dados são organizados em linhas e colunas, podendo conter diferentes tipos de dados.

a validação de relacionamentos entre as empresas e sócios, criando e associando as arestas dos subgrafos. A figura 4 ilustra como parte dos conjuntos, denominados GE, foram gerados após a execução do algoritmo.

```
def criar_grafo(socios, empresas, relacoes, chunk_size=1000):  
    """  
    Cria um grafo que representa as relações entre sócios e empresas.  
    :param socios: Lista de sócios.  
    :param empresas: Lista de empresas.  
    :param relacoes: Lista de tuplas representando relações (socio, empresa).  
    :return: Um grafo NetworkX.  
    """  
    G = nx.Graph()  
    """  
    #cria os nós do tipo sócios  
    for index, row in socios.iterrows():  
        G.add_node(row['socios'], tipo='socio')  
    #cria os nós do tipo empresas  
    for index, row in empresas.iterrows():  
        G.add_node(row['empresas'], tipo='empresa')  
    """  
    # Criar threads para adicionar nós de sócios e empresas  
    with ThreadPoolExecutor(max_workers=2) as executor:  
        #.result é utilizado para esperar a finalização da thread  
        executor.submit(adicionar_nos_socios, G, socios).result()  
        executor.submit(adicionar_nos_empresas, G, empresas).result()  
    #vincula os nós e cria as arestas do grafo  
    for row in relacoes.iterrows(index=False):  
        G.add_edge(row.socios, row.empresas)  
    return G
```

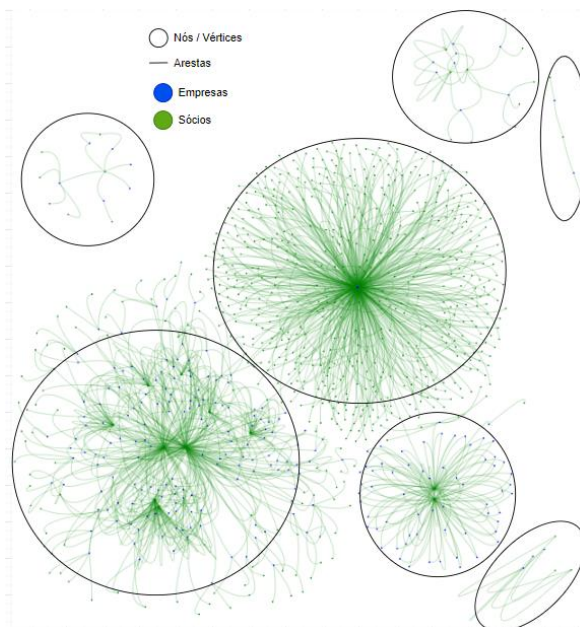


Figura 4. Grafo de referência

Fonte: Resultados originais da pesquisa

Resultados Preliminares

A seguir são apresentados os resultados do trabalho já com as imagens exportadas pelo algoritmo e como é possível identificar os vínculos entre sócios e empresas.

Essas estruturas de grafos podem ser abstraídas à uma relação entre empresas e sócios, pois sempre uma empresa possui um ou mais de um sócio responsável pela gestão da empresa. Desta forma, é possível dizer que a relação entre os indivíduos em um grafo não direcionado pode formar uma estrutura de GE, conforme visto na figura 5.




Figura 5. Grupo Econômico – Vínculo Societário

Fonte: Resultados originais da pesquisa

Na figura 5, pode-se visualizar as referências entre as empresas e sócios. É possível identificar um vínculo entre as empresas ‘FR Comércio’ e a ‘Restaurante Cantinho’ através do nó ‘AJM*’. Esse vínculo entre as empresas, por sua vez, demonstra que a análise isoladamente das empresas e sócios pode ser insuficiente ao avaliar o risco de crédito envolvido. Os vínculos entre indivíduos trazem maior visibilidade na identificação das características dos envolvidos na análise de crédito, já que dessa forma é possível identificar o poder de inferência positiva ou negativa entre os envolvidos.

Por exemplo, supondo que a empresa ‘Restaurante Cantinho’, vista na figura 5, seja uma empresa que possua alguma restrição bancária, tal como uma desonra de contrato. O fato de um dos indivíduos do grupo não possuir boa relação com o crédito pode criar uma situação negativa para todo o GE, ou seja, ao disponibilizar crédito para a empresa ‘FR Comércio’ é necessário ter maior cautela já que existe alguma restrição ativa dentro do GE.

Essa abordagem deve ser relevante com a adição de outras variáveis, ou seja, a identificação das relações entre os indivíduos não deve ser necessariamente considerada como a única forma da análise do risco de crédito envolvido, mas já garante maior visibilidade na avaliação do perfil do GE.

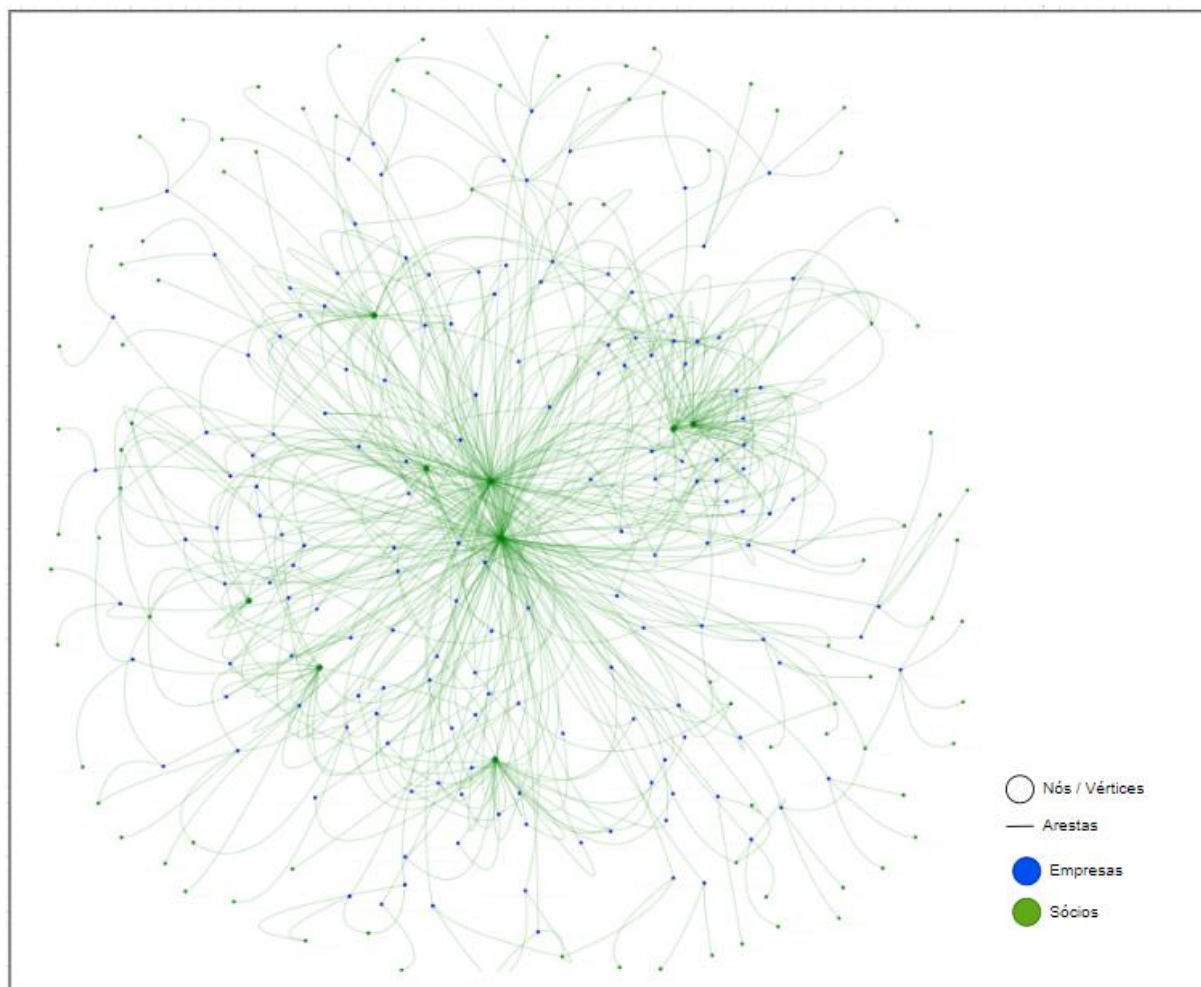


Figura 6. Grupo Econômico – Vínculo Societário com grande ramificação

Fonte: Resultados originais da pesquisa

A relação dos sócios está diretamente relacionada com a capacidade de tomada de decisão na empresa e, por isso, sócios com pouca participação societária podem não representar grande impacto ao risco envolvido. Percebe-se que ao considerar somente o vínculo entre as empresas e sócios em um GE, podemos ter grupos com muitos vínculos como visto na figura 6 e 7, trazendo talvez uma visão ofuscada em relação ao risco agregado, já que mesmo havendo vínculos entre as empresas e sócios, a distância entre os nós, pode ser muito grande e com pouca relevância para avaliação do risco de crédito.

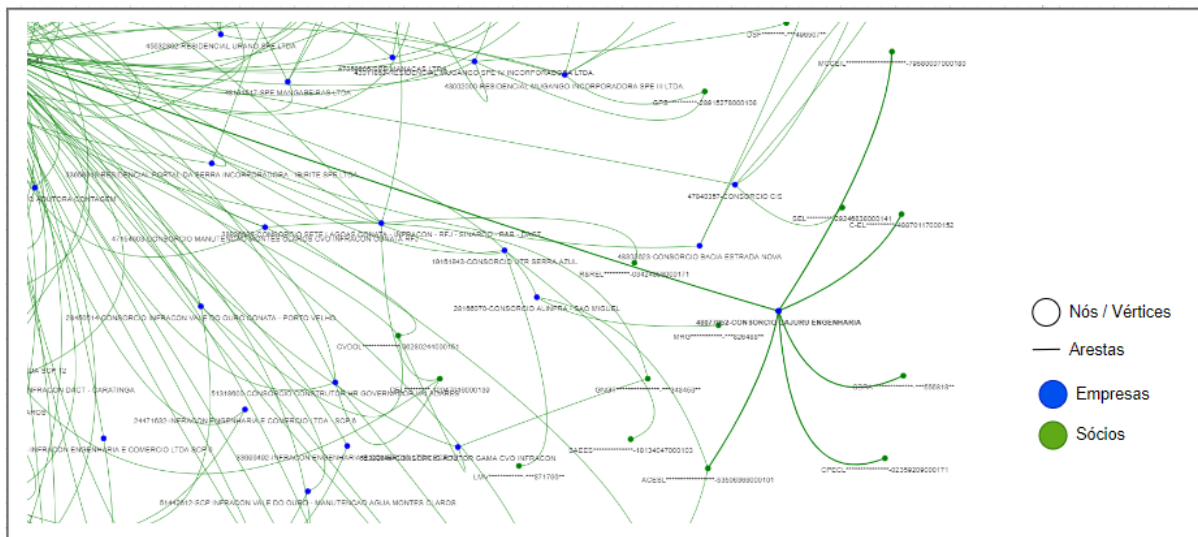


Figura 7. Grupo Econômico – Vínculo Societário – Zoom vínculo com muitas arestas e distante

Fonte: Resultados originais da pesquisa

Existe também uma abordagem para empresas compostas por muitas arestas, as quais podem ter uma grande capacidade de criação de novos vínculos, como visto na figura 6 e 7. Nesses casos, podemos considerar que a identificação de forma rápida e proativa dos novos vínculos dá maior dinamismo às IFs ao avaliar o risco de crédito inferido, permitindo uma reavaliação do nível de risco proposto para cada GE.

Conclusão

Concessão de crédito e a gestão de risco são fundamentais para assegurar a estabilidade e a sustentabilidade das IFs, pois são basicamente o núcleo de seus negócios. A evolução das abordagens na avaliação de crédito, impulsionada por inovações associadas ao incremento de tecnologias e de novos modelos, tem proporcionado uma compreensão mais aprofundada das interações econômicas e sociais. Ao introduzir o conceito de GE na análise de risco de crédito, observamos uma otimização dos métodos de avaliação, aumentando a segurança para cumprir as diretrizes definidas pelo BACEN.

Assim, o algoritmo desenvolvido simplifica a identificação das estruturas dos GEs, evidenciando os laços entre empresas e sócios a partir das participações societárias. Isso possibilitou a criação de visões claras das conexões entre seus indivíduos, aumentando a capilaridade na avaliação de risco de crédito. Essa afirmação é corroborada indiretamente com a análise demonstrada por Jesse (2020), que discorre sobre como medir e controlar o risco, utilizando métodos quantitativos e qualitativos. Segundo o autor, ao utilizar o método

quantitativo, é possível identificar variáveis como renda, taxas de juros aplicadas, prazos, histórico de inadimplência, liquidez do tomador, que podem indicar que as contrapartes envolvidas no contrato podem não respeitar os acordos firmados. Já em uma visão qualitativa, é inferido um perfil ao tomador, baseado em suas características, tais como, capacidade de honra, vínculos empregatícios legais (ex: trabalho análogo à escravidão), outros contratos em dia ou em atraso, etc.

Sendo assim, as IFs precisam controlar de forma mais eficiência a gestão do crédito e riscos. Pode ser realizada utilizando modelos estatísticos, algoritmos de aprendizado de máquina e técnicas avançadas para prever o risco associado a diferentes tipos de clientes e operações de crédito. É nesse contexto que o trabalho apresentou uma abordagem para identificar automaticamente a formação de GEs. Esses grupos, por possuírem integrantes que estão interligados economicamente, compartilham responsabilidades e riscos. Portanto, uma análise eficaz de GEs pode revelar potenciais exposições ao risco de crédito que, de outra forma, passariam despercebidas em uma avaliação isolada das variáveis quantitativas e qualitativas de cada empresa.

A automatização da identificação de GEs pode trazer inúmeros benefícios para a gestão de riscos em instituições financeiras. Em primeiro lugar, a automatização acelera o processo de análise, permitindo que grandes volumes de dados sejam processados em tempo real, possibilitando decisões mais rápidas e precisas. O reconhecimento automático de relações entre empresas e sócios, melhora a visibilidade sobre as possíveis interdependências financeiras, evitando que bancos concedam crédito a empresas cujo grupo pode estar comprometido, reduzindo assim a exposição ao risco e melhorando a alocação de capital.

O uso de grafos dirigidos e não dirigidos no algoritmo proporcionou uma representação mais clara dessas relações, destacando a importância dos vínculos diretos e indiretos e da influência mútua no processo de concessão de crédito. Por outro lado, se a identificação de GEs não for precisa, há o risco de sobrecarregar a análise de crédito com informações irrelevantes, gerando confusão sobre quais conexões afetam realmente o risco financeiro. Isso pode levar a decisões inadequadas, seja recusando crédito a empresas financeiramente sólidas ou concedendo a grupos de alto risco sem o devido cuidado.

Portanto, a identificação de GE por grafos não pode ser a única abordagem, pois o algoritmo foca somente na identificação de relações entre sócios e empresas e pode fornecer uma visão incompleta dos envolvidos na operação de crédito. Para aprimorar esse processo, sugere-se o desenvolvimento de algoritmos que incorporem variáveis adicionais e métodos de análise preditiva, como análise de redes complexas, visando gerar novas premissas mais precisas sobre as estruturas de risco e a identificação de sócios com influência decisiva no

grupo. Um exemplo disso é visto quando existem sócios minoritários presentes na formação proposta pelo algoritmo e esses sócios podem não possuir poder de decisão nas empresas e não representam positiva ou negativamente no cálculo de variáveis da concessão e risco de crédito.

Além disso, é possível vislumbrar novas direções para pesquisas futuras que podem complementar o algoritmo atual. A integração de dados alternativos, como redes sociais corporativas ou transações financeiras em tempo real, pode aumentar a precisão da identificação de GEs. O uso de algoritmos de aprendizado de máquina para prever a formação de novos grupos, ou ainda a inclusão de variáveis qualitativas sobre a reputação de sócios, são algumas das direções que poderiam tornar essa ferramenta mais robusta.

Em resumo, a análise automatizada de grupos econômicos, quando bem implementada, pode otimizar a gestão de riscos em instituições financeiras, proporcionando uma visão mais completa e eficiente das relações econômicas entre os tomadores de crédito e seus sócios. Ou seja, a implementação de modelos de grafos não pode ser considerada como o único meio de identificação de GE, mas sim um ponto de partida para identificar de forma proativa as conexões entre empresas e sócios, possibilitando às IFs se antecipar e tomarem melhores decisões na concessão e gestão de crédito.

Agradecimentos

Agradeço e dedico o esforço deste trabalho aos meus familiares e amigos que sempre me incentivaram a crescer profissional e pessoalmente.

Referências

Banco Central do Brasil [BACEN]. 2017. Resolução nº 4557, de 23 de fevereiro. Dispõe sobre a estrutura de gerenciamento de riscos e apetite por riscos nas instituições financeiras. Disponível em: <https://normativos.bcb.gov.br/Lists/Normativos/Attachments/50344/Res_4557_v1_O.pdf>. Acesso em: 10 jun. 2024.

Base dos Dados. 2023. Quadro Societário CNPJ. Disponível em: <<https://basedosdados.org/dataset/e43f0d5b-43cf-4bfb-8d90-c38a4e0d7c4f?table=81272674-f522-4e43-a70b-05bf46f0a163>>. Acesso em: 10 mar. 2024.

Camargos, M.A. 2012. A inadimplência em um programa de crédito de uma instituição financeira pública de minas gerais: uma análise utilizando regressão logística. REGE - Revista de Gestão. Disponível em: <https://www.sciencedirect.com/science/article/pii/S180_9227616303204>. Acesso em: 10 mar. 2024.

Gonçalves, Reinaldo. 1991. Grupos econômicos: uma análise conceitual e teórica. Disponível em: <<https://periodicos.fgv.br/rbe/article/view/534>>. Acesso em: 10 mar. 2024.

Google BigQuery. Serviço de armazenamento de dados. 2024. Disponível em: <<https://cloud.google.com/bigquery>>. Acesso em: 10 jun. 2024.

Governo do Brasil. Cadastro Nacional da Pessoa Jurídica – CNPJ. 2024. Disponível em: <<https://dados.gov.br/dados/conjuntos-dados/cadastro-nacional-da-pessoa-juridica---cnpj>>. Acesso em: 24 mar. 2024.

Instituto de Pesquisa Econômica Aplicada [IPEA]. 2006. Risco de Crédito: Desenvolvimento de modelo Credit Scoring para a gestão da inadimplência de uma instituição de microcrédito. Disponível em: <https://www.ipea.gov.br/ipeacaixa/premio2006/docs/trabpremiados/IpeaCaixa2006_Profissional_02lugar_tema03.pdf>. Acesso em: 30 jun. 2024.

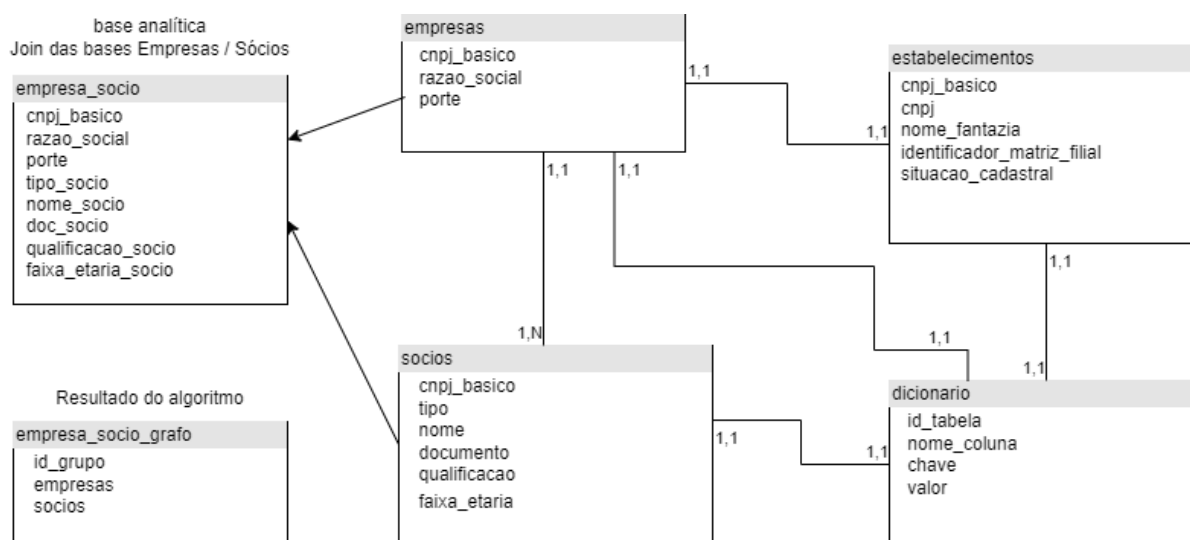
Jassé, P. 2020. Gestão Do Risco De Crédito Bancário: Estudo Empírico. Disponível em: <<https://comum.rcaap.pt/handle/10400.26/31674>>. Acesso em: 30 jun. 2024.

Gestel, T. V; Baesens, B. 2008. Credit Risk Management: Basic Concepts financial risk componentes, rating analysis, models, economic and regulatory capital. Disponível em: <https://www.academia.edu/37069057/Credit_Risk_Management_Basic_Concepts>. Acesso em: 01 abr. 2024.

Wilson, R. J. 1996. Introduction to Graph Theory. 4. ed. Harlow: Pearson Education.

Apêndice

Apêndice A – Imagem 1. Modelo de dados proposto - Data Wrangling



Legenda: Modelagem espelho bases RFB e resultado projeto.

Fonte: Resultados originais da pesquisa

Apêndice A – Imagem 2 – Data Wrangling – Plataforma Google Bigquery

The screenshot displays the Google Cloud BigQuery console interface. At the top, there's a navigation bar with the Google Cloud logo and a search bar. Below this, the 'Explorer' panel on the left shows a tree view of datasets, including 'br_me_empresa', 'br_me_estoque', and 'br_me_empresa'. The main area is titled 'Consulta sem título' and contains a SQL query. The query is a complex join between 'br_me_empresa' and 'br_me_empresa' tables, filtering for specific dates and company names. The 'Resultados da consulta' panel shows the query results in a table format. The table has two columns: 'empresas' and 'socios'. The 'empresas' column lists company names like 'ADRESSORA TRANSPORTES E SERVIÇOS LTDA' and 'MG PARTICIPAÇÕES LTDA-20893612000148'. The 'socios' column lists names like 'DANIELA RODRIGUES OLIVEIRA OSORIO' and 'AFFONSO EMPREENDIMENTOS E PARTICIPAÇÕES LTDA'. The bottom of the console shows a 'Histórico de jobs' section with a table of job execution details.

Google Cloud BigQuery console interface showing a SQL query and its results.

SQL Query:

```
1 SELECT count(*)
2 FROM basedados.br_me_empresa.estabelecimentos
3 where data = "2023-11-16"
4 and identificador_matriz_filial = "1";
5
6 select *
7 from (
8 SELECT CONCAT(a.cnpj_basico, '-', a.razao_social) as empresas, CONCAT(c.nome, '-', c.documento) as socios
9 FROM basedados.br_me_empresa.empresas a
10 inner join basedados.br_me_empresa.estabelecimentos b on a.cnpj_basico = b.cnpj_basico and b.situacao_cadastral in ("1","2","4") and b.identificador_matriz_filial = "1"
11 inner join basedados.br_me_empresa.socios c on a.cnpj_basico = c.cnpj_basico and c.data = "2023-11-16"
12 where a.data = "2023-11-16" and b.data = "2023-11-16"
13 ) as d
14 where d.empresas is not null
15 and d.socios is not null
16 limit 1000;
17
18
```

Resultados da consulta:

empresas	socios
ADRESSORA TRANSPORTES E SERVIÇOS LTDA	
MG PARTICIPAÇÕES LTDA-20893612000148	
DEB1752HOLDING CASA AFFONSO EMPREENDIMENTOS E PARTICIPAÇÕES LTDA	DANIELA RODRIGUES OLIVEIRA OSORIO***201798**

Histórico de jobs:

ID do job	Data/hora de criação	Proprietário	Tipo	Resumo	Insights	ID da sessão	Ações
...

Legenda: BigQuery – Comand Line.

Fonte: Resultados originais da pesquisa